

# **O PROTOCOLO DE MANCHESTER E A INTEGRAÇÃO DA IA: UMA SOLUÇÃO PARA A TRIAGEM HOSPITALAR NO BRASIL**

## **MANCHESTER TRIAGE PROTOCOL AND AI INTEGRATION: A SOLUTION FOR HOSPITAL TRIAGE IN BRAZIL**

**Marina Lara<sup>1</sup>**

### **RESUMO**

Este artigo aborda a implementação do Protocolo de Manchester, um sistema de classificação de risco hospitalar, no Brasil, com foco nos desafios e benefícios associados ao uso da inteligência artificial (IA) para otimizar a triagem de pacientes. Inicialmente desenvolvido em 1997 no Reino Unido, o protocolo visa priorizar o atendimento hospitalar com base na gravidade dos casos, contribuindo para a redução de mortes evitáveis e a racionalização dos recursos. No Brasil, embora implementado desde 2008, a aplicação eficaz do protocolo enfrenta barreiras significativas, como a falta de profissionais capacitados e a alta demanda nos serviços de emergência.

A metodologia do estudo incluiu a transcrição de queixas de pacientes em formato de áudio utilizando a ferramenta Speech-to-Text do Google Cloud Platform, e a aplicação do modelo de linguagem LLM da OpenAI para identificar e aplicar os fluxogramas do Protocolo de Manchester. Os resultados indicaram que o modelo de transcrição de áudio obteve um WER de 18,6%, enquanto o modelo de LLM alcançou 100% de acurácia na identificação e aplicação dos fluxogramas testados.

A integração da IA demonstrou potencial significativo para superar a escassez de profissionais qualificados e melhorar a eficiência da triagem hospitalar, especialmente em regiões remotas. Contudo, desafios como a necessidade de recursos financeiros, a adaptabilidade dos profissionais e pacientes, e questões legais relativas à privacidade dos dados foram identificados. Conclui-se que, embora promissora, a implementação da IA requer melhorias contínuas e uma adaptação cuidadosa para garantir sua eficácia e escalabilidade no contexto brasileiro.

### **ABSTRACT**

This article addresses the implementation of the Manchester Triage Protocol, a hospital risk classification system, in Brazil, focusing on the challenges and benefits associated with using artificial intelligence (AI) to optimize patient triage. Initially developed in 1997 in the UK, the protocol aims to prioritize hospital care based on the severity of cases, contributing to the reduction of avoidable deaths and resource rationalization. In Brazil, despite being implemented since 2008, effective application faces significant barriers such as a lack of trained professionals and high demand in emergency services.

The study methodology involved transcribing patient complaints from audio using Google

---

<sup>1</sup> Graduando em Ciência de Dados e Inteligência Artificial na Universidade PUC-SP – E-mail: [marinalara170303@gmail.com](mailto:marinalara170303@gmail.com)

Cloud Platform's Speech-to-Text tool, and applying OpenAI's LLM language model to identify and apply Manchester Protocol flowcharts. Results indicated that the audio transcription model achieved a WER of 18.6%, while the LLM model reached 100% accuracy in identifying and applying the tested flowcharts.

AI integration has shown significant potential to overcome shortages of qualified professionals and improve hospital triage efficiency, especially in remote regions. However, challenges such as the need for financial resources, adaptability of professionals and patients, and legal issues related to data privacy were identified. It is concluded that while promising, AI implementation requires continuous improvement and careful adaptation to ensure effectiveness and scalability in the Brazilian context.

## SUMÁRIO

<b>1 INTRODUÇÃO</b>	<b>3</b>
1.1 O protocolo Manchester	3
1.2 Os Desafios da Implementação do Protocolo no Brasil	5
1.3 Os Possíveis Benefícios da Implementação de IA	5
<b>2 METODOLOGIA</b>	<b>6</b>
2.1 Modelos Utilizados	6
2.1.1 Modelo de Transcrição de Áudio	6
2.1.2 Modelo de LLM	7
2.2 Avaliação dos Modelos	7
2.2.1 Modelo de Transcrição de Áudio	7
2.2.2 Modelo de LLM	8
2.2.2.1 Identificação do Fluxograma	8
2.2.2.2 Aplicação do Fluxograma	8
<b>3 RESULTADOS</b>	<b>9</b>
3.1 Performance dos Modelos	9
3.1.1 Modelo de Transcrição de Áudio	9
3.1.2 Modelo de LLM	10
3.1.2.1 Identificação do Fluxograma	10
3.1.2.2 Aplicação do Fluxograma	10
3.2 Comparando resultados da IA com o exigido dos profissionais	11
<b>4 DISCUSSÃO</b>	<b>11</b>
4.1 Possíveis Limitações	12
4.2 Possibilidades de Melhoria	12
4.3 Possibilidade de Escalar	13
4.4 Benefícios e Potencialidades da IA na Triage Hospitalar	13
<b>5 CONSIDERAÇÕES FINAIS</b>	<b>14</b>
<b>REFERÊNCIAS</b>	<b>15</b>
<b>LISTA DE ILUSTRAÇÕES</b>	<b>18</b>

# 1 INTRODUÇÃO

## 1.1 O protocolo Manchester

O protocolo de Manchester é um Sistema de Classificação de risco criado na cidade de Manchester, no Hospital Universitário de South Manchester, Reino Unido, em 1997 [1]. Atualmente é utilizado em diversos países, incluindo no Brasil, onde foi implementado pela primeira vez em 2008 [2]. Seu principal objetivo é melhorar a eficiência e eficácia do atendimento e rastreamento hospitalar.

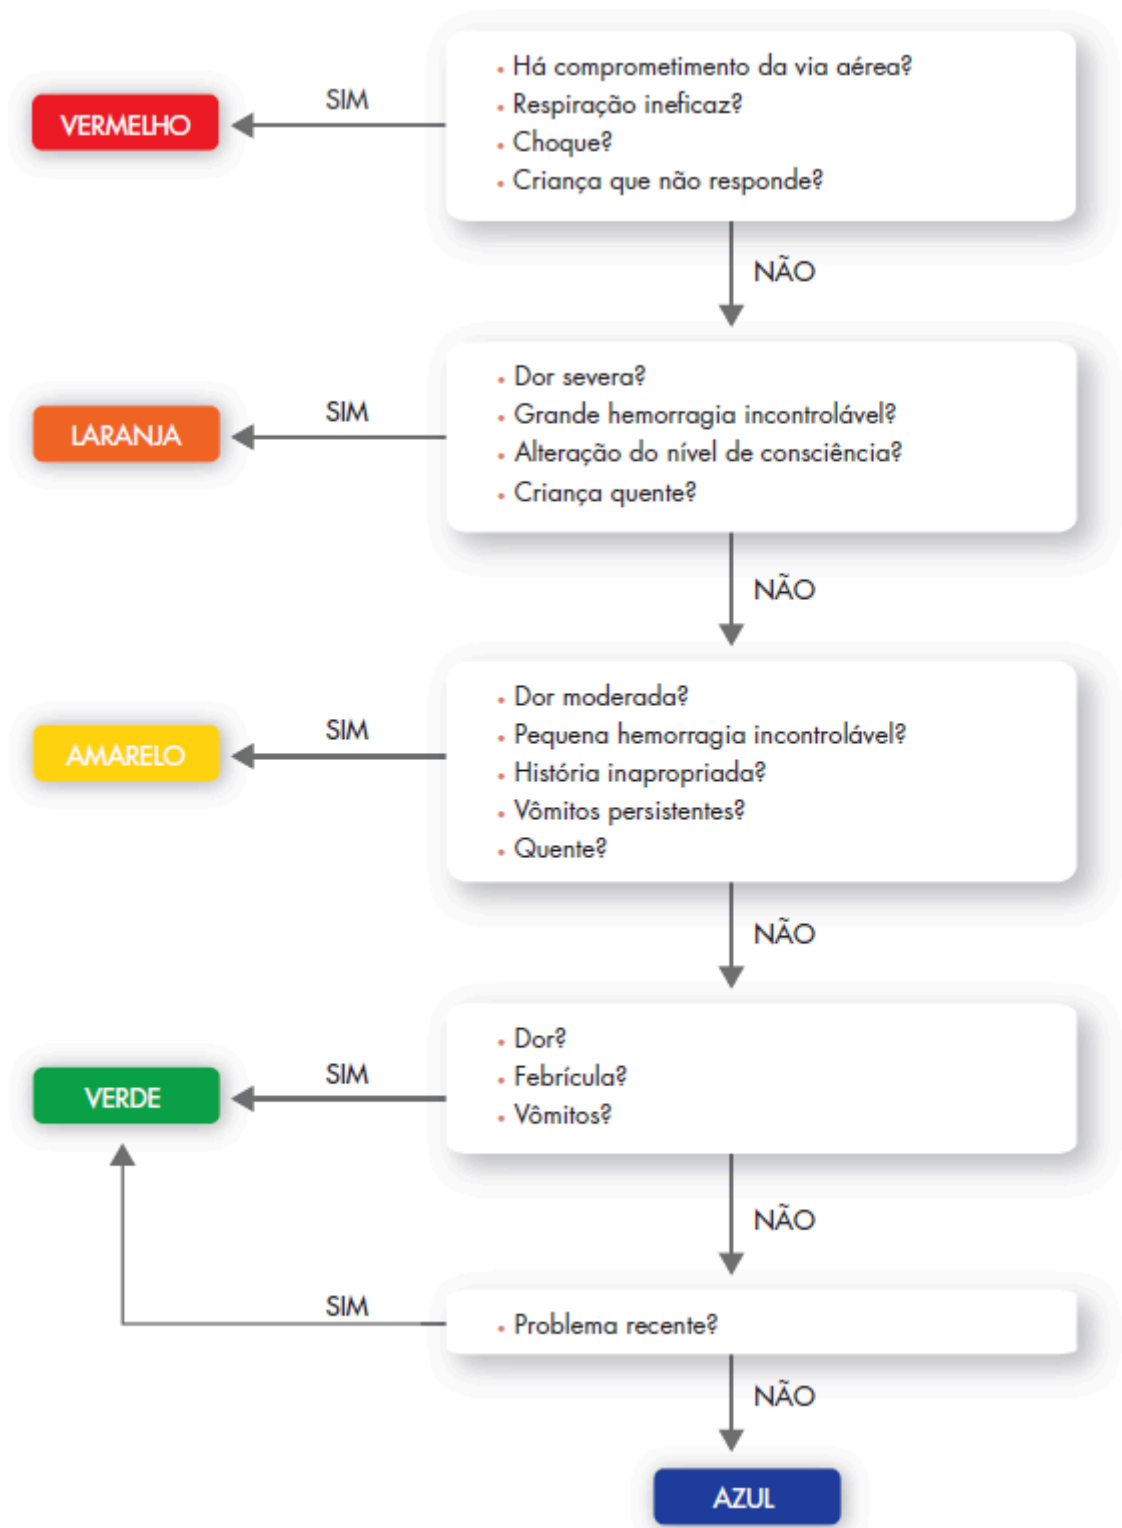
Um dos pilares do protocolo é a priorização do atendimento. Ele permite a priorização dos pacientes com base no seu nível de risco, garantindo que pacientes mais graves sejam atendidos com maior antecedência, tendo como resultado mais notório a redução dos índices de mortes evitáveis [3] e, sendo até mesmo apontado em estudos como redutor do risco de agravamento dos quadros dos pacientes antes do primeiro atendimento médico, aumento da satisfação do usuário e dos profissionais de saúde, além de contribuir para a racionalização do consumo de recursos [4]. Para que seja feita essa priorização, ele é composto por 5 níveis de risco, representados por cores, que indicam tanto a gravidade quanto o tempo de atendimento adequado para aquele paciente. A tabela a seguir reúne as informações retiradas do livro Sistema Manchester de Classificação de Risco, do Grupo Brasileiro de Classificação de Risco [24]. Nela é abordado cada nível de classificação com seu respectivo nome, cor e tempo-resposta máximo:

### Nomenclatura do Sistema Manchester de Classificação de Risco

Nível	Nome	Cor	Tempo-resposta máximo (min.)
1	Emergência	Vermelho	0
2	Muito urgente	Laranja	10
3	Urgente	Amarelo	60
4	Pouco urgente	Verde	120
5	Não urgente	Azul	240

A padronização do atendimento também é outro dos benefícios mais importantes do protocolo. Desta forma, os pacientes são também beneficiados, pois sabem que independente do dia, horário ou profissional, irão receber o mesmo tipo de atendimento e, inclusive, terão uma estimativa do tempo médio para que ele ocorra [6]. Para isso, o protocolo é composto por 52 fluxogramas que englobam diferentes condições que o paciente pode estar enfrentando. Abaixo podemos observar o exemplo de um desses fluxogramas, o de Risco de Morte, retirado do livro Sistema Manchester de Classificação de Risco:

**Figura 1: Fluxograma de Risco de Morte do Protocolo Manchester**



*Triagem no Serviço de Urgência/emergência: Grupo de Triagem de Manchester. Portugal: Grupo Português de Triagem – BMJ-Publishing Group, FREITAS, 1997.*

Por definição, qualquer queixa deve se encaixar em um dos fluxos, facilitando a atuação do profissional. Essa classificação é a primeira etapa de todo o atendimento do paciente, o que garante que quadros menos graves não sejam priorizados em detrimento de mais graves [7].

## **1.2 Os Desafios da Implementação do Protocolo no Brasil**

O enfermeiro é o profissional mais adequado para implementar o protocolo [8]. Para isso, ele precisa ter algumas habilidades imprescindíveis, como, escuta qualificada, raciocínio clínico, agilidade para a tomada de decisões, além de claro, certificação do conhecimento do protocolo [9][16][17] .

Em 2008, foi constituído o Grupo Brasileiro de Classificação de Risco (GBCR) com o objetivo de promover revisões, adaptações e auditorias do CRPM [10], mas ainda sim, nem todos os hospitais brasileiros têm profissionais capacitados para aplicar o protocolo ou acesso à estrutura necessária - como a equipe de auditoria [19]. Em 2006, o Ministério da Saúde do Brasil declarou que a uniformização dos atendimentos das emergências poderia ser alcançada por medidas como investimento financeiro e capacitação de profissionais de saúde, inclusive o treinamento de enfermeiros para a utilização de sistemas de triagem [11]. Em 2012, no artigo Classificação de risco em serviços de emergência: uma discussão da literatura sobre o Sistema de Triagem de Manchester [12], os autores também sugerem a capacitação dos enfermeiros responsáveis pela triagem. Entretanto, já em 2019, no estudo Dificuldades Encontradas Pelos Profissionais de Saúde à Implementação da Classificação de Risco no Setor de Urgência e Emergência [13], os autores citam como algumas das principais dificuldades identificadas para a implementação da classificação de risco a alta demanda e falta de capacitação.

## **1.3 Os Possíveis Benefícios da Implementação de IA**

Nesse contexto, a integração da inteligência artificial (IA) emerge como uma solução promissora para superar as limitações impostas pela falta de profissionais qualificados. A aplicação de algoritmos de IA na triagem hospitalar oferece a vantagem de uma abordagem automatizada e precisa, capaz de classificar os pacientes de acordo com o Protocolo de Manchester, principalmente em locais onde profissionais habilitados são escassos. Ao utilizar dados clínicos e indicadores vitais, os sistemas de IA podem identificar rapidamente os casos de maior gravidade, permitindo uma intervenção precoce e eficaz, mesmo em ambientes com falta de profissionais qualificados.

Considerando isso, este artigo propõe explorar o potencial da IA na triagem hospitalar, especialmente em regiões remotas do Brasil, onde a escassez de profissionais de saúde representa um desafio significativo. Deste modo, ao examinar a eficácia e as

vantagens dessa abordagem inovadora, espera-se fornecer insights valiosos para aprimorar a prestação de serviços de saúde nessas áreas e, consequentemente, melhorar os resultados clínicos e a qualidade de vida dos pacientes.

## 2 METODOLOGIA

A metodologia do estudo seguiu o seguinte processo metodológico:

- A. **Processar Queixa:** Inicialmente, é necessário obter a queixa do paciente. Esse dado foi fornecido no formato de áudio, mais especificamente na extensão wav. Os dados foram processados e convertidos para o formato de texto.
- B. **Identificar Fluxograma:** A próxima etapa é identificar qual fluxograma melhor se encaixa àquela queixa inicial. Para isso foi utilizado um modelo de LLM (large language model) capaz de retornar o fluxo mais adequado com base num contexto pré-definido.
- C. **Aplicar o Fluxograma:** A etapa final é a aplicação do fluxograma em si e envolve novamente o modelo de LLM, para que possamos chegar a classificação correta com base nas outras queixas e condições do paciente.

Identificamos que todas as três etapas se beneficiaram em performance com um fine tuning dos seus modelos com dados específicos da área médica. Os dados e códigos utilizados em todo o processo estão disponíveis no repositório no Github deste artigo [25] e entraremos em detalhes sobre o processo de modelagem e avaliação nos próximos tópicos:

### 2.1 Modelos Utilizados

#### 2.1.1 Modelo de Transcrição de Áudio

Para a transcrição de áudio foi utilizada a ferramenta Speech-to-Text do Google Cloud Platform. Esta ferramenta é robusta e projetada para automatizar a transcrição de áudio em texto de forma a facilitar a integração com diversos serviços, por ser escalável e flexível.

O modelo em si, utiliza técnicas avançadas de Machine Learning, como redes neurais, para cumprir seu propósito de transcrição com altos níveis de acurácia e precisão. Além disso, a biblioteca incorpora técnicas de processamento de linguagem natural para melhorar a compreensão e interpretação da fala, utilizando modelos de linguagem personalizados e análise de contexto [21]. Ele é treinado com quantidades massivas e variadas de dados, o que o torna extremamente escalável e adaptável a idiomas e sotaques distintos [20]. Isso é essencial para o nosso estudo, visto que queremos propor a implementação do mesmo em diversos estados do Brasil, e, como um país de dimensões

continentais, possui sotaques e variações linguísticas extremamente diversas [26].

### **2.1.2 Modelo de LLM**

Um LLM é um modelo de linguagem treinado para processar e gerar texto. O LLM da empresa OpenAPI, é composto por um conjunto de redes neurais que combinam conceitos de Machine Learning e Deep Learning. Ele é treinado em conjuntos massivos de dados, o que dá a ele a capacidade de boa performance em diversos contextos. Isso é importante para o nosso estudo, que, além de possuir conjunto de texto de pessoas de origens diversas do Brasil, também trata de um assunto bastante específico com vocabulário bastante especial, que é a triagem hospitalar [22].

Para a aplicação do protocolo Manchester, foi empregada a biblioteca Langchain-OpenAI, que fornece uma camada de abstração para interação com a API da OpenAPI e de outros Large Language Models (LLMs). Essa biblioteca contribui para economia de custos, pois otimiza o uso dos modelos com técnicas de caching, seleção de modelo e métodos de recuperação de dados otimizados. Isso é importante para tornar a nossa aplicação escalável. [23]

## **2.2 Avaliação dos Modelos**

Para avaliar a eficiência dos modelos utilizamos as seguintes fontes de dados e metodologias:

### **2.2.1 Modelo de Transcrição de Áudio**

Para a validação do modelo de transcrição de áudio em texto utilizamos vídeos disponíveis no youtube de práticas de OSCE (Objective Structured Clinical Examination), totalizando 40 minutos de áudio. A escolha dessa base se deve principalmente a utilização de um vocabulário pertencente ao meio da saúde. É importante destacar a variedade de qualidade de áudio, sotaques e dialetos de regiões distintas do Brasil contida nos áudios. O processo para construir a base de validação foi feito a partir do processo de anotação de sentenças manual das falas.

Para avaliar a performance utilizamos a métrica WER (Word Error Rate), uma das métricas recomendadas pela literatura e a mais comumente utilizada. Ela utiliza a soma das substituições, deleções e inserções necessárias para transformar a transcrição do modelo na transcrição correta. O WER varia de 0 a 1, e quanto menor o seu valor, melhor a performance do modelo [14].



## 2.2.2 Modelo de LLM

### 2.2.2.1 Identificação do Fluxograma

Para a validação do modelo de LLM na parte da identificação do fluxograma a ser utilizado, construímos uma base de dados de validação com a ajuda de 7 enfermeiros habilitados a aplicar o protocolo de Manchester. Eles simularam possíveis queixas iniciais e qual seria o fluxograma correto para cada uma delas. Uma amostra da base construída está na tabela a seguir:

Amostra	Queixa Inicial	Fluxograma
A	Adulto de 30 anos procura a emergência relatando dor de garganta há 4 dias com febre.	Dor de garganta no adulto
B	Adulto entra na emergência andando, relatando dor forte lombar do lado tipo cólica. início repentina há uma hora.	Dor Lombar
C	Adulto andando com dor de coluna lombar há 15 dias. Relata dor aos movimentos que irradia para a perna.	Dor Lombar

Tendo a base de validação com as Queixas Iniciais e os devidos Fluxogramas Correspondentes, fornecemos como entrada para o modelo a listagem dos 55 fluxogramas disponíveis, as Queixas Iniciais e solicitamos como retorno em qual fluxograma cada um desses exemplos se encaixava.

### 2.2.2.2 Aplicação do Fluxograma

Para avaliar a performance do modelo de LLM em aplicar os fluxogramas, utilizamos a mesma base de dados anterior, porém, com mais informações. Para além da queixa inicial, temos: dados de sinais vitais do paciente: como frequência cardíaca, saturação de O<sup>2</sup> no sangue, temperatura corporal, nível de consciência, e nível de dor

As condições do fluxograma a ser aplicado: em quais critérios o paciente deve se enquadrar para que possa ser classificado em cada uma das cores

A cor de classificação: em qual cor ele se enquadrou.

Os itens do tópico I são os únicos não obrigatórios, e temos uma amostra da base de dados na figura a seguir:

Amostra	Nível de Dor (0 à 10)	Temperatura	Classificação
A	3	38.6	Amarelo
B	6	36	Amarelo
C	3		Azul

A partir dessas informações, esperava-se que o modelo apontasse a correta classificação de risco para cada uma das amostras.

### 3 RESULTADOS

#### 3.1 Performance dos Modelos

##### 3.1.1 Modelo de Transcrição de Áudio

Em nossa análise obtivemos um WER total de 18,6%. Entretanto, nos áudios com maior qualidade, o WER médio foi de 10,8%. Ou seja, a qualidade do áudio e os ruídos do ambiente são fatores fundamentais para o bom desempenho do modelo. Portanto, garantir um ambiente silencioso e bons equipamentos de áudio são parte importante para a implementação deste modelo.

Vídeo	Duração (min)	Baixa Qualidade do Áudio	Alta Incidência de Ruídos	Região do Brasil de Origem	WER
1	2,9	Sim	Sim	Sudeste	41,1%
2	10,2	Sim	Sim	Nordeste	33,7%
3	8,3	Não	Sim	Sul	9,4%
4	6,6	Não	Não	Sudeste	12,2%
5	5,7	Não	Não	Sudeste	9,7%
6	5,9	Não	Não	Sudeste	13,8%
<b>Total</b>	<b>39,6</b>				<b>18,6%</b>

### 3.1.2 Modelo de LLM

O modelo de LLM foi bem sucedido na avaliação de todos os casos apresentados, apresentando as mesmas respostas dadas pelos enfermeiros na construção da base. Podemos ver detalhadamente na figura 3.1 e descrito nos tópicos abaixo.

#### 3.1.2.1 Identificação do Fluxograma

Obteve-se uma acurácia de 100% para os dados de validação. Isso indica que o modelo identificou corretamente o fluxograma a ser utilizado 100% das vezes.

#### 3.1.2.2 Aplicação do Fluxograma

A acurácia da aplicação do fluxograma também atingiu 100% , ou seja, o modelo classificou corretamente todas as observações da base de teste.

Queixa Inicial	Saturação	Nível de Dor (0 à 10)	FC (Frequência Cardíaca)	Temperatura	Nível de Consciência	Fluxograma		Classificação (Cor)	
						Validação	Indicado Pelo Modelo	Validação	Indicada pelo Modelo
Adulto de 30 anos procura a emergência relatando dor de garganta há 4 dias com febre.		3		38.6		Dor de garganta no adulto	Dor de garganta no adulto	Amarelo	Amarelo
Adulto entra na emergência andando, relatando dor forte lombar do lado tipo cólica. início repentina há uma hora.		6		36		Dor Lombar	Dor Lombar	Amarelo	Amarelo
Adulto andando com dor de coluna lombar há 15 dias. Relata dor aos movimentos que irradia para a perna.		3				Dor Lombar	Dor Lombar	Azul	Azul
Homem de 67 anos procura o serviço de emergência com dor no peito tipo aperto no	95	5	88			Dor torácica	Dor torácica	Laranja	Laranja

centro do peito de início há 2 horas.									
Mãe entra na triagem com a criança de 1 ano convulsionando.						Convulsão	Convulsão	Vermelho	Vermelho
Mulher de 33 anos com dor de cabeça, tontura e história de desmaio hoje.		5		36.8	15	Cefaléia	Cefaléia	Amarelo	Amarelo
					<b>Acurácia</b>	100%		100%	

### 3.2 Comparando resultados da IA com o exigido dos profissionais

De acordo com Grupo Brasileiro de Classificação de Risco, os critérios estabelecidos pelo Grupo de Triagem Manchester para a realização das auditorias internas são [31] :

Aferição	Desempenho
$\geq 80\%$	Bom
$> 90\%$	Muito Bom
$> 95\%$	Excelente

Dessa forma, se aplicarmos essa avaliação em nosso modelo para os exemplos trabalhados, podemos dizer que ele atingiu um desempenho excelente e, considerando apenas esse aspecto de avaliação, estaria apto a aplicar o protocolo de Manchester. Entretanto, é de suma importância ressaltar a natureza diferente das condições às quais o modelo foi testado e a das que seriam enfrentadas numa situação real e que, ainda sim, existe a necessidade de replicar esse teste para uma base de dados mais abrangente para que possamos validar esse resultado.

## 4 DISCUSSÃO

O presente estudo propõe a implementação da IA visando, principalmente, as vantagens que ela traria para a triagem hospitalar, especialmente em locais remotos do Brasil onde há escassez de profissionais qualificados. A utilização da IA na triagem pode proporcionar assistência eficaz na priorização de atendimento, garantindo que pacientes críticos sejam atendidos mais rapidamente, o que pode ser vital em situações de emergência.

A integração da IA na triagem hospitalar enfrenta alguns desafios, como a alta demanda por serviços de saúde e a falta de capacitação adequada para manusear e interagir com essas ferramentas. A alta demanda pode sobrecarregar os sistemas de IA, comprometendo a

eficiência e a eficácia dos atendimentos. Além disso, a falta de capacitação dos profissionais de saúde para interagir com a IA e interpretar seus resultados, tal como a falta de familiaridade e confiança dos pacientes na tecnologia pode limitar os benefícios potenciais. É crucial que esses desafios sejam abordados para garantir a implementação bem-sucedida da IA na triagem hospitalar, portanto, iremos discuti-los mais profundamente nos tópicos seguintes.

#### 4.1 Possíveis Limitações

Durante a escrita deste artigo, foram identificadas várias limitações que devem ser consideradas para que a implementação da IA seja bem-sucedida:

- **Recursos financeiros:** A implementação de sistemas de IA pode ser custosa, exigindo investimentos significativos em tecnologia, infraestrutura e treinamento.
- **Adaptabilidade dos profissionais e pacientes:** A resistência à mudança e a falta de familiaridade com novas tecnologias podem dificultar a adoção da IA por parte de profissionais de saúde e pacientes.
- **Autorização prévia para o processamento de dados:** Questões legais e de privacidade relacionadas ao processamento de dados dos pacientes devem ser resolvidas, garantindo que a coleta e o uso de dados sejam feitos de maneira ética e conforme a legislação vigente.
- **Qualidade e integridade dos equipamentos:** A preservação dos equipamentos utilizados na implementação da IA é crucial, pois a deterioração dos dispositivos pode comprometer a eficácia dos sistemas. É necessário garantir ambientes favoráveis e sem ruídos para o funcionamento adequado dos equipamentos.

#### 4.2 Possibilidades de Melhoria

Como uma Prova de Conceito (POC), as soluções implementadas neste estudo deixam abertas diversas possibilidades de melhoria, incluindo a sofisticação das técnicas já usadas e espaço para novas implementações. Algumas sugestões incluem:

- **Dispensar a necessidade de um profissional intermediário:** Na nossa POC, ainda não dispensamos a necessidade de um profissional intermediário entre a IA e o paciente. No entanto, melhorias como o reconhecimento de imagem para avaliar o estado físico do paciente e suas expressões faciais, além da implementação de mecanismos para a IA fazer mais perguntas caso não tenha um alto nível de confiança no seu resultado, podem reduzir essa necessidade.
- **Adaptação de acordo com a idade do paciente:** O sistema deve ser capaz de adaptar-se conforme a idade do paciente, considerando necessidades específicas como por exemplo de crianças, bebês ou idosos.

- **Avaliação global do paciente:** A IA deve ser capaz de avaliar o paciente como um todo, considerando informações além dos sinais vitais e da queixa inicial, como expressões faciais, forma de falar e discurso. Isso previne que usuários propositalmente influenciem o resultado da IA e aumenta a integridade e a confiabilidade dos diagnósticos.
- **Fine tuning dos modelos:** É necessário aplicar fine tuning nos modelos, focados nas técnicas de avaliação qualitativa e quantitativa indicadas pelo Grupo Brasileiro de Classificação de Risco, como nível de dor [29], nível de consciência, possível sepse, entre outros pontos importantes segundo o Grupo Brasileiro de Classificação de Risco [28] [30].

#### 4.3 Possibilidade de Escalar

Com as melhorias citadas no ponto 5.2 e considerando as limitações mencionadas no ponto 5.1, há uma oportunidade significativa para implementar a solução em grande escala. Isso se deve ao caráter de fácil implementação, personalização e melhoria contínua que os modelos de IA possibilitam. Para acompanhar o desempenho, devem ser feitas auditorias semelhantes às realizadas com os profissionais que utilizam o protocolo de Manchester, monitorando o número de acertos e erros de classificação, conforme citado no livro Sistema Manchester de Classificação de Risco [31]. Além disso, é importante monitorar a performance do modelo de forma granular, dividindo os dados por horário de atendimento, idade do paciente, sexo do paciente, grau de urgência indicado, entre outros. Esse tipo de controle específico ajuda a identificar vieses no modelo, que, segundo SURI levam prejuízo a performance do mesmo por estar tendo suas saídas enviesadas [24].

#### 4.4 Benefícios e Potencialidades da IA na Triagem Hospitalar

A implementação da IA na triagem hospitalar oferece vários benefícios e potencialidades:

- **Melhoria na eficiência do atendimento:** A IA pode processar grandes volumes de dados rapidamente. No nosso contexto, permitiria uma triagem mais rápida e eficiente dos pacientes.
- **Redução de erros humanos:** A IA pode ajudar a reduzir erros humanos na avaliação inicial dos pacientes, proporcionando diagnósticos mais precisos e confiáveis. existem pesquisas que mostram que a inteligência artificial (IA) pode superar os médicos humanos na análise de exames de imagem médica em alguns casos [32].
- **Acesso a atendimento em áreas remotas:** A IA pode ser particularmente útil em áreas remotas onde há falta de profissionais de saúde qualificados,

aumentando as chances de que os pacientes recebam uma avaliação inicial adequada.

- **Exemplos práticos de sucesso:** Em países como os Estados Unidos e o Reino Unido, a IA já foi implementada com sucesso em vários hospitais para melhorar a triagem e o atendimento de emergência.
  - **Sistema de triagem baseado em IA da Babylon Health:** A empresa criou um sistema de triagem com inteligência artificial para ajudar pacientes a avaliar seus sintomas e determinar o nível adequado de atendimento médico [34]. Utilizando processamento de linguagem natural e algoritmos de aprendizado de máquina, o sistema faz perguntas detalhadas e fornece recomendações. Estudos de validação mostraram que o desempenho do sistema é de 90,2%, e comparável ao de enfermeiros, que é de 73,5% de precisão nas recomendações. Implantado em Ruanda e projetado para integração com sistemas de saúde, o sistema ainda não está integrado aos registros de pacientes no NHS (National Health Service) - o sistema público de saúde do Reino Unido [33].
  - **Assistente Digital de Saúde da Buoy Health:** É uma ferramenta baseada em IA que ajuda as pessoas a entender seus sintomas e navegar pelo sistema de saúde [18]. Utiliza inteligência artificial e processamento de linguagem natural para oferecer insights personalizados e recomendações, além de ferramentas para verificação de seguros, localização de provedores e agendamento de consultas. Todo o conteúdo é revisado por especialistas médicos. Apesar de ser uma ferramenta promissora e a empresa afirmar ter uma precisão diagnóstica na faixa de 90,9% a 98%, avaliações independentes identificaram áreas para melhoria na precisão e adequação de sua análise de sintomas e recomendações de cuidados comparadas a outros verificadores de sintomas com IA [15].

A implementação da IA na triagem hospitalar tem o potencial de transformar o sistema de saúde, melhorando a eficiência, reduzindo erros e proporcionando acesso a cuidados de qualidade em áreas remotas. No entanto, para alcançar esses benefícios, é essencial abordar os desafios e limitações identificados, investindo em recursos financeiros, treinamento e infraestrutura adequados.

## 5 CONSIDERAÇÕES FINAIS

A conclusão deste estudo ressalta a eficácia e as vantagens da implementação da inteligência artificial (IA) no processo de triagem hospitalar baseado no Protocolo de Manchester. Através da análise, constatou-se que os modelos de IA utilizados, incluindo a transcrição de áudio e o processamento de linguagem natural, apresentaram alta acurácia na identificação e aplicação dos fluxogramas do protocolo. Essa eficiência demonstra o potencial da IA para melhorar significativamente a priorização e o atendimento de pacientes em emergências hospitalares, especialmente em regiões remotas do Brasil onde a escassez de profissionais qualificados é um desafio constante.

As principais descobertas indicam que a IA pode automatizar com precisão a triagem, proporcionando uma resposta mais rápida e eficaz aos casos de maior gravidade, reduzindo assim a incidência de mortes evitáveis e aumentando a satisfação dos pacientes e profissionais de saúde. No entanto, desafios como a necessidade de investimentos financeiros, a adaptação cultural e operacional dos profissionais e pacientes, e as questões legais relacionadas à privacidade dos dados precisam ser abordados para uma implementação bem-sucedida.

A importância do uso de IA na triagem hospitalar é evidente, oferecendo uma solução viável para melhorar a qualidade e a eficiência dos serviços de saúde em locais com recursos limitados. Futuras pesquisas devem focar em aprimorar os modelos de IA, aumentar a robustez contra variações na qualidade dos dados de entrada, e explorar a integração de tecnologias adicionais, como o reconhecimento de imagens e a análise de expressões faciais, para fornecer uma avaliação ainda mais completa e precisa dos pacientes. Além disso, a criação de políticas e frameworks legais que garantam a segurança e a privacidade dos dados dos pacientes será crucial para a aceitação e a expansão dessa tecnologia.

## REFERÊNCIAS

- [1] HAY, E.; BEKERMAN, L.; ROSEMBERG, G. Peled R. Quality assurance of nurse triage: consistency of results over three years. *Am J Emerg Med*, v. 19, n. 2, p. 113–117, 2001.
- [2] FILHO, L. A. M. Revisão sistemática do Sistema de Triagem de Manchester na estratificação de risco. Universidade Federal da Bahia - Faculdade de Medicina da Bahia, Junho 2013.
- [3] DE MELLO KATIUCIA MARTINS BARROS DAYRREL, R. B. C. H. F. R. L. T. DE C. E. S. R. A. ACOLHIMENTO COM CLASSIFICAÇÃO DE RISCO: PROPOSTA DE HUMANIZAÇÃO NOS SERVIÇOS DE URGÊNCIA. *Revista de Enfermagem do Centro do Centro*, p. 437, dez. 2012.
- [4] Coutinho AAP. Classificação de risco nos serviços de emergência: uma análise para além da dimensão técnico assistencial [tese]. Belo Horizonte: Universidade Federal de Minas Gerais; 2010. 206 p.
- [5] Coutinho AAP, Cecílio LC de O, Mota JAC. Classificação de risco em serviços de emergência: uma discussão da literatura sobre o Sistema de Triagem de Manchester. *Rev Médica Minas Gerais*. 2012, Vol. 22(2), Pag. 188–98.
- [6] Disponível em:



<[https://www.interdisciplinaremsaude.com.br/Volume\\_9/Trabalho\\_09.pdf](https://www.interdisciplinaremsaude.com.br/Volume_9/Trabalho_09.pdf)>. Acesso em: 13 jun. 2024.

[7] SANTOS, M. A. Acolhimento com classificação de risco: um fio guia da administração em emergência. *Revista Saúde e Desenvolvimento*, [S. l.], v. 6, n. 3, p. 56–69, 2014.

Disponível em:

<https://www.revistasuninter.com/revistasaude/index.php/saudeDesenvolvimento/article/view/323>. Acesso em: 27 jun. 2024.

[8] Souza CC. Grau de concordância de classificação de risco de usuários atendidos 918 *Revista da Universidade Vale do Rio Verde, Três Corações*, v. 12, n. 2, p. 905-920, ago./dez. 2014 em um pronto-socorro utilizando dois diferentes protocolos [dissertação]. Universidade Federal de Minas Gerais. Belo Horizonte (MG); 2009

[9] RONCALLI, A. A.; OLIVEIRA, D. N. de; SILVA, I. C. M.; BRITO, R. F.; VIEGAS, S. M. da F. PROTOCOLO DE MANCHESTER E POPULAÇÃO USUÁRIA NA CLASSIFICAÇÃO DE RISCO: VISÃO DO ENFERMEIRO. *Revista Baiana de Enfermagem*, [S. l.], v. 31, n. 2, 2017. DOI: 10.18471/rbe.v31i2.16949. Disponível em: <https://periodicos.ufba.br/index.php/enfermagem/article/view/16949>. Acesso em: 3 jun. 2024.

[10] FRANCISCO, Glaucia Taborda M .LIMA, Izaura Alberton, 2014

[11] MINISTÉRIO DA, S. Política Nacional de Atenção às Urgências. 3.ed. Brasília: Editora do Ministério da Saúde. [s.l: s.n.].

[12] COUTINHO, A.; CECÍLIO, L.; MOTA, J. Classificação de risco em serviços de emergência: uma discussão da literatura sobre o Sistema de Triagem de Manchester. *Rev Med Minas Gerais*, v. 22, n. 2, p. 188–198, 2012.

[13] ABREU, J. G. et al. Dificuldades encontradas pelos profissionais de saúde à implementação da classificação de risco no setor de urgência e emergência. [s.l: s.n.].

[14] HUANG, X.; ACERO, A.; HON, H.-W. Spoken Language Processing: A guide to theory, algorithm, and system development. Old Tappan, NJ, USA: Prentice Hall, 2001.

[15] ČIRKOVIĆ, A. Evaluation of Four artificial intelligence–assisted self-diagnosis apps on three diagnoses: Two-year follow-up study. *Journal of medical internet research*, v. 22, n. 12, p. e18097, 2020.

[16] MACKWAY-JONES, K.; MARSDEN, J.; WINDLE, J. Sistema Manchester de Classificação de Risco. Versão brasileira de Cordeiro Jr Welfane; Rausch MCP. Grupo Brasileiro de Classificação de Risco. Belo Horizonte: Folium, 2018.

[17] INOUE, K. C. et al. Avaliação da qualidade da Classificação de Risco nos Serviços de Emergência. *Acta Paulista de Enfermagem*, v. 28, n. 5, p. 420–425, 2015.

[18] Buoy health. Disponível em:

<<https://accelerator.childrenshospital.org/portfolio/buoy-health/>>. Acesso em: 27 jun. 2024.

[19] SACOMAN, T. M. et al. Implantação do Sistema de Classificação de Risco Manchester em uma rede municipal de urgência. *Saúde em Debate*, v. 43, n. 121, p. 354–367, 2019.

[20] Idiomas com suporte da Speech-to-Text. Disponível em:

<[https://cloud.google.com/speech-to-text/docs/speech-to-text-supported-languages?hl=pt-br&\\_gl=1\\*y9cj62\\*\\_up\\*MQ..&gclid=Cj0KCQjw0\\_WyBhDMARIsAL1Vz8uM1IGkgHTMbp4tTXjRGPgfM7sQP\\_ZLDYp\\_pSlfADCvEtoBnLJTZYZ8aAsGkEALw\\_wcB&gclsrc=aw.ds](https://cloud.google.com/speech-to-text/docs/speech-to-text-supported-languages?hl=pt-br&_gl=1*y9cj62*_up*MQ..&gclid=Cj0KCQjw0_WyBhDMARIsAL1Vz8uM1IGkgHTMbp4tTXjRGPgfM7sQP_ZLDYp_pSlfADCvEtoBnLJTZYZ8aAsGkEALw_wcB&gclsrc=aw.ds)>.

Acesso em: 13 jun. 2024.

[21] CHOI, J. et al. Design of voice to text conversion and management program based on Google cloud speech API. 2018 International Conference on Computational Science and Computational Intelligence (CSCI). *Anais...IEEE*, 2018.

[22] WU, S. et al. NExT-GPT: Any-to-Any Multimodal LLM. 2023.

[23] OpenAI. Disponível em:

<<https://python.langchain.com/v0.2/docs/integrations/platforms/openai/>>. Acesso em: 13 jun. 2024.

[24] SURI, J. S. Understanding the bias in machine learning systems for cardiovascular disease risk assessment: The first of its kind review. *Computers in biology and medicine*, v. 142, 2022.

[25] LARA, M. Manchester. Disponível em: <<https://github.com/Marina-Lara/Manchester>>. Acesso em: 13 jun. 2024.

[26] DACOREGIO, C. DE S. As práticas e técnicas de suavização de sotaque no português brasileiro como tentativa de homogeneizar o uso da língua. UFFS, 14 dez. 2021.

[27] WINDLE, K. M.-J. J. M. Processo de Tomada de Decisão e a Classificação de Risco. Em: sistema manchester de classificação de risco 2a edição. [s.l.] Grupo Brasileiro de Classificação de Risco, 2010. p. 7–12.

[28] WINDLE, K. M.-J. J. M. Método de Classificação de Risco. Em: sistema manchester de classificação de risco 2a edição. [s.l.] Grupo Brasileiro de Classificação de Risco, 2010. p. 13–26.

[29] WINDLE, K. M.-J. J. M. Avaliação da dor como Parte do Processo de Classificação de Risco. Em: sistema manchester de classificação de risco 2a edição. [s.l.] Grupo Brasileiro de Classificação de Risco, 2010. p. 27–36.

[30] WINDLE, K. M.-J. J. M. Classificação de Risco e Gestão de Pacientes. Em: sistema manchester de classificação de risco 2a edição. [s.l.] Grupo Brasileiro de Classificação de Risco, 2010. p. 37–44.

[31] WINDLE, K. M.-J. J. M. Auditoria do Sistema de Triagem de Manchester. Em: sistema manchester de classificação de risco 2a edição. [s.l.] Grupo Brasileiro de Classificação de Risco, 2010. p. 46–58.

[32] GICHOYA, J. W. et al. Phronesis of AI in radiology: Superhuman meets natural

stupidity. 2018. Disponível em: <<http://arxiv.org/abs/1803.11244>>.

[33] BAKER, A. et al. A comparison of artificial intelligence and human doctors for the purpose of triage and diagnosis. *Frontiers in artificial intelligence*, v. 3, p. 543405, 2020.

[34]~HEATHER, B. Babylon Health launches new AI triage tool. Disponível em: <<https://www.digitalhealth.net/2016/06/babylon-health-launches-new-ai-triage-tool/>>. Acesso em: 27 jun. 2024.

## **LISTA DE ILUSTRAÇÕES**

- Figura 1 - 1997 — Triagem no Serviço de Urgência/emergência: Grupo de Triagem de Manchester. Portugal: Grupo Português de Triagem – BMJ-Publishing Group. p.154